

Илья Беляков

г. Москва

belyakovilya755@gmail.com

+7 917 973-76-79

tg: @belyakovilya

Образование

Москва, НИУ ВШЭ, студент 2 курса Бакалавриата Факультета Физики

Профильные дисциплины: Линейная алгебра, Математический анализ, Теория вероятности, Обработка и анализ данных.

Дополнительное образование: Яндекс Образование — Учебник по машинному обучению, Онлайн платформа - «Университет Искусственного Интеллекта», Deep Learning School.

Участник [Инженерно-математической школы НИУ ВШЭ и ВК](#) проекта RnD инструментов MLSecOps.

Учебные проекты

Ссылка на проекты: <https://github.com/Ilya-Belyakov/Pet-Projects>

- В рамках проекта RnD инструментов MLSecOps исследовал инструменты evasion black-box атак на модели машинного обучения.

Цель: Собрать информацию о существующих алгоритмах evasion black-box атаках. Проверить работоспособность инструментов для атак.

Задачи:

- Найти инструменты, реализующие алгоритмы black-box атак, проверить работоспособность на задаче классификации mnist. Найти и изучить оригинальные статьи алгоритмов атак.
- Придумать классификацию и собрать информацию об атаках в единую таблицу.
- Применить атаки на модели CatBoost на задаче классификации датасета с категориальными данными adult и на задаче ранжирования датасета msrank.

- **Исследование Language-Image модели OpenCLIP**

Цель: Исследовать возможности применения модели.

Задачи:

- Реализовать задачу классификации без учителя Zero-Shooting
- Реализовать Retrieval task – поиск наиболее подходящего изображения по тексту
- Визуализировать распределение эмбедингов изображений

- Реализовать атаку поиска слепых зон модели, зашумленное изображение должно перестать подходить к текстовому описанию оригинального изображения
- **Исследование Membership Inference attack на модель классификации решающего леса.**

Цель: Проверить возможность атаки на модель типа черной коробки.

Задачи:

- Определить подход обработки данных из которого можно будет получить набор признаков необходимых для успешной атаки
- Реализовать атаку